

Relatório Técnico 1

Dashboard Pão dos Pobres

Gustavo Losch¹, Henrique Mayer¹, Henrique Kops¹

¹ Escola Politécnica – Pontifícia Universidade Católica do Rio Grande do Sul (PUCRS)

{g.losch, h.ramos, h.kops}@edu.pucrs.br

1. Introdução

A Fundação Pão dos Pobres desempenha um papel social fundamental, gerando um relatório mensal com dados operacionais por meio do seu Levantamento Estatístico Mensal (LEM). Contudo, o armazenamento histórico dessas informações ocorria de maneira descentralizada e não padronizada em diversas planilhas eletrônicas. Essa fragmentação estrutural impõe barreiras significativas para a extração de *insights*, a análise contínua de séries temporais e, conseqüentemente, para a tomada de decisões baseada em dados por parte dos gestores.

Para solucionar esse problema, este projeto tem como objetivo desenvolver um *dashboard* para centralizar e analisar as métricas operacionais da instituição. Este relatório documenta a estruturação dessa solução, detalhando desde a rotina de pré-processamento até a definição das perguntas de negócio e da arquitetura visual que irão compor a ferramenta.

2. Conjunto de Dados

2.1. Características

O conjunto de dados base para este projeto provém do Levantamento Estatístico Mensal (LEM) da Fundação Pão dos Pobres, englobando o histórico de múltiplos anos dos programas de acolhimento, aprendizagem profissional e convivência. Conforme destacado na introdução, a disposição original dessas informações priorizava estritamente a leitura humana e a emissão de relatórios impressos, o que resultou em planilhas de formatação complexa e pouco adequadas ao processamento computacional. Entre os principais desafios estruturais encontrados estão a mescla de categorias fundamentais em uma mesma dimensão, como áreas de atuação e tipos de atendimento, e a restrição na granularidade temporal da base: os registros encontram-se previamente agregados em totais mensais, limitando o acesso aos registros brutos não agregados de cada atendimento.

Além da complexidade estrutural, a análise inicial dos arquivos revelou problemas na padronização e na organização dos registros. Observou-se o uso frequente de marcadores de texto, como a letra “X”, e de espaços em branco no lugar do número zero para indicar a ausência de atendimentos. Outro desafio encontrado foi a desorganização no armazenamento, pois a pasta de dados continha diversos documentos parciais misturados aos arquivos anuais definitivos, o que gerava risco de duplicação ou de conflito de informações.

2.2. Pré-Processamento

Para solucionar as falhas estruturais e viabilizar o consumo das informações por um *dashboard*, foi desenvolvida uma rotina automatizada em linguagem Python. O fluxo de

pré-processamento baseou-se no paradigma de Extração, Transformação e Carga (ETL), convertendo planilhas eletrônicas de formatação complexa em um modelo tabular padronizado e unidimensional. O conjunto de dados resultante foi estruturado a partir de seis colunas essenciais: (a) tipo, que define o serviço ou indicador específico do atendimento; (b) área, que designa o grupo de atuação ao qual o tipo pertence (como Saúde ou Educação); (c) status, que especifica a situação do beneficiário (como “matriculados” ou “aguardando vaga”, aplicável somente aos casos de ensino, permanecendo `none` para áreas que não ensino); (d) mês e ano, que estabelecem o marco temporal de cada registro e (e) valor, que traz a quantificação numérica exata dos atendimentos prestados. Todo processo de padronização foi organizado nas seguintes etapas de pré-processamento:

- **Descoberta e filtragem de arquivos:** O algoritmo varre o diretório `data/input/LEM/` em busca de arquivos `.xlsx`. Durante a inspeção inicial, constatou-se a existência de múltiplos arquivos referentes a um mesmo ano, que divergiam apenas na completude dos dados mensais. Assumiu-se a premissa de que as planilhas contendo valores nulos a partir de determinado mês consistiam em relatórios de preenchimento parcial, enquanto aquelas com registros contínuos em todos os meses representavam os consolidados anuais. A partir dessa constatação, os arquivos parciais foram rotulados manualmente com o sufixo `_partial`. Para assegurar a integridade do conjunto de dados, a rotina foi programada para ignorar intencionalmente qualquer documento com essa etiqueta, evitando a inclusão de informações incompletas. Em paralelo, o ano de referência é extraído dinamicamente da nomenclatura do arquivo (ex.: `LEM_2023.xlsx`) por meio de expressões regulares.
- **Identificação da estrutura:** Devido à variação na posição dos cabeçalhos ao longo dos anos, a rotina percorre as linhas iniciais de cada planilha até identificar uma que contenha ao menos três meses válidos (ex.: “JAN”, “FEV”, “MAR”). Esse procedimento mapeia automaticamente quais colunas representam os dados mensais.
- **Extração da área:** O processamento das planilhas ocorre de forma sequencial, linha a linha, de modo que o algoritmo consiga registrar e manter o contexto das informações lidas. Ao localizar palavras-chave na primeira coluna, o sistema atualiza automaticamente a área de atuação vigente (como Saúde ou Educação). Esse método sequencial também permite mapear a dependência entre os dados: ao identificar uma categoria principal (ex.: Ensino Infantil), o *script* vincula as linhas subsequentes como suas respectivas subcategorias (ex.: Matriculados, Aguardando Vaga), preservando a hierarquia estrutural original sem misturar as informações.
- **Limpeza e normalização de valores:** Células vazias ou marcadas com caracteres não numéricos (“X”) são convertidas para zero. Valores contendo vírgulas como separadores decimais são adequados para o padrão computacional com ponto. Ademais, os textos de áreas e meses são padronizados para letras minúsculas e sem acentuação, o que facilita o funcionamento dos filtros no painel de visualização.
- **Agregação dos dados:** Após o processamento individual de cada planilha anual, as informações são integradas em uma base de dados única. Cada registro mensal passa a ocupar uma linha única, composta por sete colunas: tipo, status, área, mês, ano, valor numérico e arquivo de origem. Essa unificação elimina a fragmentação

dos dados e viabiliza a análise de séries temporais, permitindo a comparação direta do desempenho e da demanda dos programas sociais ao longo de múltiplos anos.

O resultado final desse fluxo é a consolidação de todos os anos no arquivo `processed.csv`, gerando uma tabela limpa e pronta para o consumo, como apresentado na Tabela 1. Essa etapa transformou dados anteriormente desorganizados em aproximadamente 1920 registros estruturados. Com as informações agora categorizadas em quatro áreas principais de atendimento, Desdobramentos Técnicos, Profissionalização, Saúde e Educação, a base de dados viabiliza possibilita a criação de análises para o projeto.

Tabela 1. Exemplo de cinco registros aleatórios do conjunto de dados após o pré-processamento.

Categoria	Status	Área	Mês	Ano	Valor	Arquivo
Ensino infantil	aguardando vaga	educacao	MAR	2021	4.0	LEM_2021.xlsx
Saude mental	none	saude	AGO	2022	0.0	LEM_2022.1.xlsx
Internações	none	saude	OUT	2022	0.0	LEM_2022.1.xlsx
Desligamentos	none	desdobramentos tecnicos	OUT	2022	0.0	LEM_2022.1.xlsx
Atendimentos individual	none	desdobramentos tecnicos	MAI	2025	49.0	LEM_2025.3.xlsx

2.3. Análise Exploratória

Com os dados processados, possuímos oito colunas, sendo sete delas de dimensões analíticas (metadados) e uma dedicada à valores numéricos (`valor`). Ao analisar a coluna de valor sem filtros relacionados à área, percebe-se uma quantidade expressiva de registros zerados (cerca de 43%) e uma distribuição de densidade concentrada nos valores mais baixos, comportamento evidenciado pelo histograma apresentado na Figura 1.

Entrando em cada uma das áreas de atendimento definidas, percebemos comportamentos estatísticos distintos que explicam essa assimetria geral (Figura 2). A área de Desdobramentos Técnicos concentra o maior volume absoluto da amostra (1.020 registros) e apresenta uma média de 10,71 atendimentos por registro. No entanto, possui um desvio padrão elevado (14,33), indicando uma alta variância e dispersão nos dados mensais.

Em contraste, as áreas de Educação e Profissionalização refletem a maior parte dos valores zerados do conjunto, cerca de 80% e 60% de seus valores zerados respectivamente. Ambas possuem medianas iguais a zero, o que mostra estatisticamente a alta incidência de meses sem novos registros ou atendimentos computados nessas categorias, puxando suas médias para baixo (1,03 e 4,55, respectivamente).

Por fim, a área de Saúde exibe o comportamento mais consistente. Embora seja a área com o menor número de linhas no conjunto de dados (180 registros), destaca-se por apresentar a maior média (13,16) e a maior mediana (12,0) entre todas as categorias. Isso sugere um fluxo de atendimento contínuo e regular, com a menor proporção de valores zerados na prestação do serviço.

3. Perguntas de Negócio

O ponto de partida para a definição das visualizações foi a identificação das principais lacunas de conhecimento que a gestão da Fundação enfrenta ao analisar os dados do LEM.




Figura 1. Distribuição geral e concentração da variável valor.




Figura 2. Percentual de valores zerados agrupados por área.

Dado que os registros disponíveis até o momento descrevem atendimentos nas áreas de Profissionalização e Desdobramentos Técnicos com maior regularidade e consistência, as perguntas foram formuladas com foco nessas dimensões, a fim de extrair o máximo de valor da base consolidada antes de ampliar o escopo da análise.

As perguntas de negócio definidas para esta primeira versão do painel são:

1. **Qual é a taxa de conversão nos cursos profissionalizantes?** Dentre os adolescentes encaminhados para cursos profissionalizantes, quantos foram efetivamente inseridos? Essa pergunta busca identificar se há uma perda significativa entre o encaminhamento e a participação real nos cursos, apontando possíveis gargalos no processo.
2. **Qual é a taxa de conversão no mercado de trabalho?** Dentre os adolescentes encaminhados para o mercado de trabalho, quantos foram efetivamente inseridos? De forma análoga à pergunta anterior, o objetivo é verificar se o volume de encaminhamentos se traduz em inserções reais e como essa relação evoluiu ao longo do tempo.
3. **Como é o fluxo de entrada e saída ao longo do tempo?** O objetivo é monitorar o volume de novas admissões (entradas) em contrapartida aos desligamentos (saídas) dos programas. Essa análise permite identificar padrões de sazonalidade, períodos de maior rotatividade e auxiliar no planejamento de vagas e alocação de infraestrutura da instituição.

Além das perguntas diretamente comparativas, o painel também deverá oferecer uma visão geral da evolução temporal dos atendimentos por área e da proporção entre as categorias, servindo como ponto de entrada para a exploração dos dados. Cabe destacar que o escopo atual da análise é delimitado pela compreensão parcial das regras que regem os dados: questões pendentes junto aos responsáveis pela Fundação poderão revelar novas dimensões analíticas e ampliar as perguntas de negócio em versões futuras do painel.

4. Ambiente de Desenvolvimento

O ambiente de desenvolvimento do painel foi estruturado com base em duas ferramentas principais: Streamlit e Plotly. A escolha do Streamlit como base da aplicação se justifica

pela sua capacidade de transformar scripts Python em aplicações interativas sem a necessidade de desenvolvimento de infraestrutura adicional de front-end. Isso permite que a equipe concentre o esforço no tratamento dos dados e na lógica das visualizações, acelerando o ciclo de desenvolvimento e facilitando eventuais ajustes conforme o entendimento do negócio evolui.

Para as visualizações, optou-se pelo Plotly, uma biblioteca que oferece gráficos interativos nativamente compatíveis com o Streamlit. A integração entre as duas ferramentas permite que o usuário interaja diretamente com os gráficos, como aplicar zoom, isolar séries ou inspecionar valores pontuais ao passar o cursor, sem que isso exija configuração adicional. Essa interatividade é especialmente relevante para um painel analítico, pois permite que os gestores explorem os dados de forma autônoma.

5. Dashboard

O *dashboard* será organizado em duas abas complementares. A primeira oferece uma visão panorâmica dos dados, com informações sobre a distribuição proporcional dos atendimentos por área e a evolução dos volumes ao longo do tempo. A segunda aprofunda a análise nas perguntas de negócio definidas, comparando diretamente os encaminhamentos e as inserções nas frentes de profissionalização e mercado de trabalho.

5.1. Visão Geral

A seção inicial do painel apresenta dois elementos visuais destinados a contextualizar o conjunto de dados para o usuário. O primeiro é um gráfico de barras empilhadas exibindo a proporção de atendimentos por área ao longo dos anos, permitindo identificar quais frentes concentram maior volume e como essa distribuição se alterou com o tempo. O segundo é uma série temporal com o total mensal de atendimentos agregados, que oferece uma leitura rápida da sazonalidade e de eventuais variações estruturais no fluxo de atendimento da Fundação.

Essa camada serve como ponto de entrada para o painel: antes de responder às perguntas específicas, o gestor pode se situar no contexto geral dos dados e identificar períodos ou áreas que merecem atenção mais detalhada.

5.2. Análise de Conversão

A segunda aba do *dashboard* responderá diretamente às perguntas de negócio por meio de dois gráficos de linhas sobrepostos, um para a frente de profissionalização e outro para a inserção no mercado de trabalho. Em cada gráfico, duas linhas representam, respectivamente, o volume de encaminhamentos e o volume de inserções efetivas ao longo do tempo, tornando visível a diferença entre a demanda registrada e o resultado alcançado.

A leitura comparativa entre os dois gráficos é facilitada pelo alinhamento visual paralelo, que permite ao usuário observar, simultaneamente, como cada frente se comporta e se o padrão de conversão das duas segue trajetórias semelhantes ou divergentes. Filtros laterais permitem selecionar o intervalo de anos analisado, tornando a exploração mais flexível. Indicadores numéricos de taxa de conversão média são exibidos acima de cada gráfico como complemento à leitura visual.

Assim como o escopo das perguntas de negócio, a estrutura do painel foi desenhada para ser extensível: à medida que novas informações forem obtidas junto à equipe

da Fundação, novas seções poderão ser acrescentadas sem que seja necessário reorganizar a arquitetura atual.

5.3. Fluxo de Atendimentos

Para responder à terceira pergunta de negócio, o painel contará com uma visualização em formato de histograma focada na distribuição das movimentações dos beneficiários. O gráfico apresentará, lado a lado, a frequência mensal de novos ingressos e de desligamentos. Essa abordagem permite que os gestores visualizem a densidade e os picos de rotatividade ao longo do ano. Ao observar a distribuição dessas entradas e saídas no histograma, torna-se possível identificar comportamentos sazonais, como meses com maior evasão ou períodos de alta concentração de matrículas, fornecendo recursos para um planejamento mais assertivo.

6. Conclusão

Este relatório documentou a etapa inicial do projeto, que consistiu no pré-processamento e na padronização dos dados históricos do Levantamento Estatístico Mensal (LEM). Com a base de dados estruturada, as próximas etapas focarão no desenvolvimento do dashboard interativo utilizando Streamlit e Plotly. A aplicação em desenvolvimento será dividida em duas frentes principais: uma visão geral da evolução dos atendimentos da instituição e uma análise específica das taxas de conversão de adolescentes em cursos profissionalizantes e no mercado de trabalho. O objetivo final é entregar uma ferramenta simples e funcional que centralize essas informações, permitindo que a gestão acompanhe os indicadores de forma contínua.